1 | 把研究故事讲清楚

这次汇报最重要的变化

上次主要证明联合选择流程能够运行。这次补上了HTRU2完整验证、稳定性和污染测试、固定预算消融、传统方法及PowerSHAP比较，以及四组合成实验。当前能够说清哪些模块在什么条件下有帮助，也保留了不支持原先预期的结果。

研究目标是同时减少训练样本和原始变量，并考察预测损失、选择稳定性和计算代价。ASSS是其中的特征选择模块，不是整个框架的名称。它依据子集模型重新训练后的效用估计特征贡献，再加入方差修正、波动惩罚和冗余惩罚。外层测试集保持完整，不参与选择。

约两分钟开场稿

老师好，这次汇报接着9月30日的内容。上次已经跑通联合样本与特征选择，但稳定性、污染敏感性和外部方法比较还不充分。这一个月我主要围绕这些缺口补充实验，并把每一项结果与保存的预测、选择记录和复核记录对应起来。

第一部分是HTRU2。联合选择能把训练矩阵压缩到原来的35%，但平均F1由0.8743降到0.8638，而且五折中有两折超过预设损失上限。完整流程重抽样和污染测试也没有显示稳定性或稳健性的普遍优势。

第二部分是比较和机制验证。传统五折结果中，ASSS与平均Shapley相同，低于L1选择；原生PowerSHAP的平均F1也更高。不过它选择四个或六个特征，不能当成完全相同规模的比较。合成实验则显示，方差修正确实降低了指定估计误差，冗余惩罚在相关分组中改善了覆盖和预测，而波动惩罚没有表现出一致收益。

所以我希望把论文贡献收敛为一个可复现的联合选择框架，以及对各模块适用条件和失败情况的实证分析，而不是声称整体方法普遍优于现有方法。接下来需要综合现有证据、完善英文正文，并与您讨论应优先解释波动惩罚、补WDBC，还是增加更独立的验证。

讲述顺序与完成边界

先交代压缩与预测的权衡，再讲对照方法，最后用合成实验解释模块。审计和复现用于支持结果可信，不宜用拟合次数代替科学贡献。传统及原生PowerSHAP五折比较已交付，四组合成层也已计算；A3/A4的综合分析、阶段收尾和整篇论文仍未完成。

2 | HTRU2、消融与跨数据集结果怎么解释

压缩是明确结果，预测保持是另一件事

HTRU2有17,898条记录、8个变量，正类占9.16%。五折开发验证中，全量、仅样本选择、联合选择的平均F1分别为0.8743、0.8732、0.8638；保留训练单元分别为100%、50%、35%。这里的训练单元比例等于保留行比例乘以保留变量比例，不代表实际运行时间减少了同样比例。

F1综合精确率和召回率，本项目使用正类F1及固定0.5阈值。联合减全量的差值约为-0.0105，即低约1.05个百分点；这不是相对下降1.05%。内层允许损失0.01用于挑选候选，但外层仍有2/5折越界，说明内层可行条件不能保证未见数据上的损失。

两种稳定性实验不能混为一谈

完整流程稳定性在十次训练集重抽样中重新选择样本策略和特征数量。联合选择的Nogueira为0.4974，顺序选择为0.6549；平均Jaccard分别为0.7352和0.8519。Nogueira会校正随机一致性的影响，1表示观察到完全一致，接近0表示类似随机选择，可能为负；它不是分类准确率。Jaccard衡量两次所选集合的重合比例。

固定预算消融则始终保留一半样本、四个变量。三个模块的135个主F1差值均为零，八种配置在十次重抽样中的集合稳定性均为1。这说明该固定条件下关闭模块没有改变最终集合，不能说稳定惩罚带来了完美稳定，也不能否定前面的完整流程波动。完整路径仍在22/135个预测对比中改变。

污染与跨数据集：保留不利结果

10%训练行受到规定的数值扰动后，联合F1为0.8167，全量为0.8228。联合方法从干净条件下降得较少，但起点也更低，不能据此宣称抗污染更强。该实验固定干净数据下的预算和策略，只重建所选对象，也不是实际天文测量噪声模型。

WDBC只完成折0、1、2：联合平均F1为0.9560，全量为0.9672，联合有2/3折超过损失上限；剩余两折暂缓，不能写成完整五折或普遍跨数据集结论。Adult训练侧小规模探测预计需243.82小时，超过48小时门槛，因此正式实验未启动，官方测试集未使用。这个时间是外推估计，不是已经跑完的耗时。

3 | A3：把ASSS放到现有方法中比较

比较设置与五折结果

A3使用同一HTRU2外层划分和共同逻辑回归。最终模型使用本折完整训练池（ρ=1），不压缩训练行；贡献估计的重抽样属于内部计算。六个传统选择器保留四个特征，全八特征作为参照。表中为各折等权平均。A3与半样本消融、自适应联合选择的设置不同，数值不能混用。

选择方法	特征数	平均F1
ASSS 111	4	0.861801
Mean Shapley	4	0.861801
L1系数选择	4	0.872498
随机森林MDI	4	0.863574
Forward CV	4	0.867402
随机选四个	4	0.859102
全部特征（参照）	8	0.874328
原生PowerSHAP	4或6	0.868810

传统比较支持什么

ASSS与Mean Shapley在五折中的F1逐折完全相同。相对L1、Forward CV和随机四特征的平均差值分别为-0.010697、-0.005601和+0.002699。因此，可以报告ASSS在该设置下高于随机选择的平均值，但不能据此认为复杂模块优于均值贡献或较强传统方法。

这些是同一个开发数据集的五折，训练部分相互重叠，也曾被前期研究使用。五折完整是覆盖范围完整，不等于五个独立数据集，更不自动产生统计显著性或独立确认结论。

Mean Shapley直接按平均贡献选择，提供"额外修正和惩罚是否值得"的对照；随机四特征提供同数量下的基本参照。L1系数、随机森林重要性和前向交叉验证分别代表不同选择机制。比较的目的不是只挑一个容易超过的基线，而是检验新增复杂度是否带来可观察收益。

PowerSHAP需要主动说明的限制

10月29日完成的原生PowerSHAP五折，实际选中特征数为4、6、6、6、4。它先用CatBoost完成原生选择，再交给共同的逻辑回归评估；ASSS采用自己的贡献估计机制。两者既有数量差异，也有选择器内部学习器差异。

ASSS减PowerSHAP的平均F1为-0.007009，约低0.70个百分点，五折中一折较高、四折较低。这个结果应如实报告，但不能解释成在相同四特征预算下PowerSHAP胜出，也不能把差值归因于某一个模块。若需要固定特征数的额外对照，应另行定义，不能在看过结果后改写本次原生比较。

F1以固定阈值判断正负；ROC AUC概括不同阈值下的排序表现；AP关注精确率与召回率关系，在正类较少时有补充价值。PowerSHAP平均ROC AUC为0.976313、AP为0.923112。多个指标提供不同侧面，不能事后挑选最有利的一项替代预先确定的主指标。

4 | A4：三个模块为什么要分开讨论

实验单位与C、S、R的含义

每个合成层有八个独立生成的数据集，每个包含600条训练数据、2,000条独立测试数据，再做六次嵌套选择。独立单位是数据集，48次选择不是48个独立数据集。XOR的RF和LR共用同一批八个数据集及划分，所以四层不能合称32个独立数据集。

C修正贡献方差中的有限排列误差；S从平均贡献中扣除一定比例的贡献标准差；R惩罚与已选变量的冗余。111表示三者开启，111-101隔离S，111-110隔离R。本组合成主设置固定选两个特征，使用B=4次贡献重抽样、M=64个排列。

C：估计更准确，不等于预测必然更好

观察到的贡献波动同时包含数据重抽样差异和有限排列造成的估计噪声。C减去估计的蒙特卡洛方差，负值截为零，避免把计算噪声全当成数据不稳定。在四层各八个数据集中，M=16和64时的原始修正及截断修正都降低了指定诊断均方误差。

这里的参照是同四个已实现博弈中精确Shapley贡献的样本方差，不是已知的总体方差。误差变小支持该有限设计下的估计改进；不能直接推导特征集合更好、预测更高或总体不确定性被准确刻画。精确值只作事后诊断，没有进入选择。

S与R的证据方向不同

信号加噪声场景中，开启S后Nogueira平均下降0.118750，弱信号遗漏增加0.104167，F1下降0.002076；八个数据集有四个变差、四个持平。可能存在对弱而有用信号惩罚过强的机制，但当前只能作为解释假设，不能把原因写成已经证实。

相关分组场景中，开启R使组覆盖增加0.145833、同组多选减少0.291667，噪声数量不变，F1增加0.019557；六个数据集改善、两个持平。它支持在这个生成机制下避免重复选同组信息，但特征层面的稳定性方向混合，不宜扩展成普遍稳定性提升。

相关分组里四个变量都参与真实生成模型，但只能保留两个。因此“组覆盖”是在两个信息组中各选代表，不是恢复全部四个信号。组覆盖和同组多选还受固定数量约束，不能当成两份完全独立的成功证据。

XOR：选择效果依赖学习器能否表达交互

XOR中，111配置的RF联合恢复率为1.0000、F1为0.9435；无交互项的线性LR分别为0.0833和0.4945。固定RF流程能利用这类交互，当前LR流程大多失败。这是同一生成机制下两个固定配置的描述性差异。RF的各CSR配置在选两个变量时结果相同，所以RF表现好不能用来证明任何单一模块有效。

5 | 导师可能提问，以及建议讨论的下一步

1．没有全面优于基线，论文贡献在哪里？

可以定位为共同性能约束下的联合选择框架，以及模块作用条件的系统评估。当前具体正证据是C的诊断误差改善和R在相关分组中的收益，同时说明S及整体ASSS的限制。是否构成足够的学位贡献，应与导师讨论，不能由结果整理代替学术判断。

2．为什么不直接使用L1？

在目前HTRU2四特征比较中，L1的平均F1确实更好，应承认它是有竞争力的简单方案。联合框架还研究样本压缩、模块估计和选择行为，但这些额外目标不自动抵消预测劣势，也不能作为忽略L1结果的理由。

3．既然稳定性曾经达到1，为什么又说不稳定？

稳定性等于1发生在固定样本比例、固定四特征的消融设计。完整流程会重新决定预算和策略，联合Nogueira只有0.4974。两者回答不同问题；必须在报数时同时说清哪个流程被重复。

4．为什么不调整S，把结果做得更好？

可以提出新设计，但本轮冻结结果必须保留。先分析弱信号被惩罚的可能原因，再预先定义新的参数、数据角色和比较标准，使用新实验验证；不能用同一批外层结果反复调整，再把它们当独立证据。

5．C降低误差，为什么最终集合可能不变？

方差估计更准确未必改变特征排序，也可能不足以跨过贪心选择的决策边界。C改善的是一个中间估计量；集合、稳定性和预测是后续不同终点，应分别检查，不能跳过中间环节推论。

6．压缩了数据，能说更快吗？

目前只能报告减少了最终训练矩阵。选择本身需要重复训练，且缓存与共享计算使逐方法时间难以直接比较。要声称端到端更快，需要包含选择开销的隔离计时；拟合次数或矩阵比例不能替代这一证据。

7．现在最应补什么？

先把已完成结果统一到英文方法、结果和讨论中，明确每项主张的来源与限制。再请导师确定优先方向：解释或修订S、补完WDBC剩余两折，或设计更独立的外部验证。这些是建议议题，不是导师已经同意的安排。

汇报结束时的建议表达

我想请您重点判断两点：是否认可把论文重点收敛为联合选择框架与模块适用边界；在此基础上，最必要的补充验证是哪一项。当前实验交付已有可追溯记录，但综合论证、整篇论文及相关阶段收尾仍需继续。